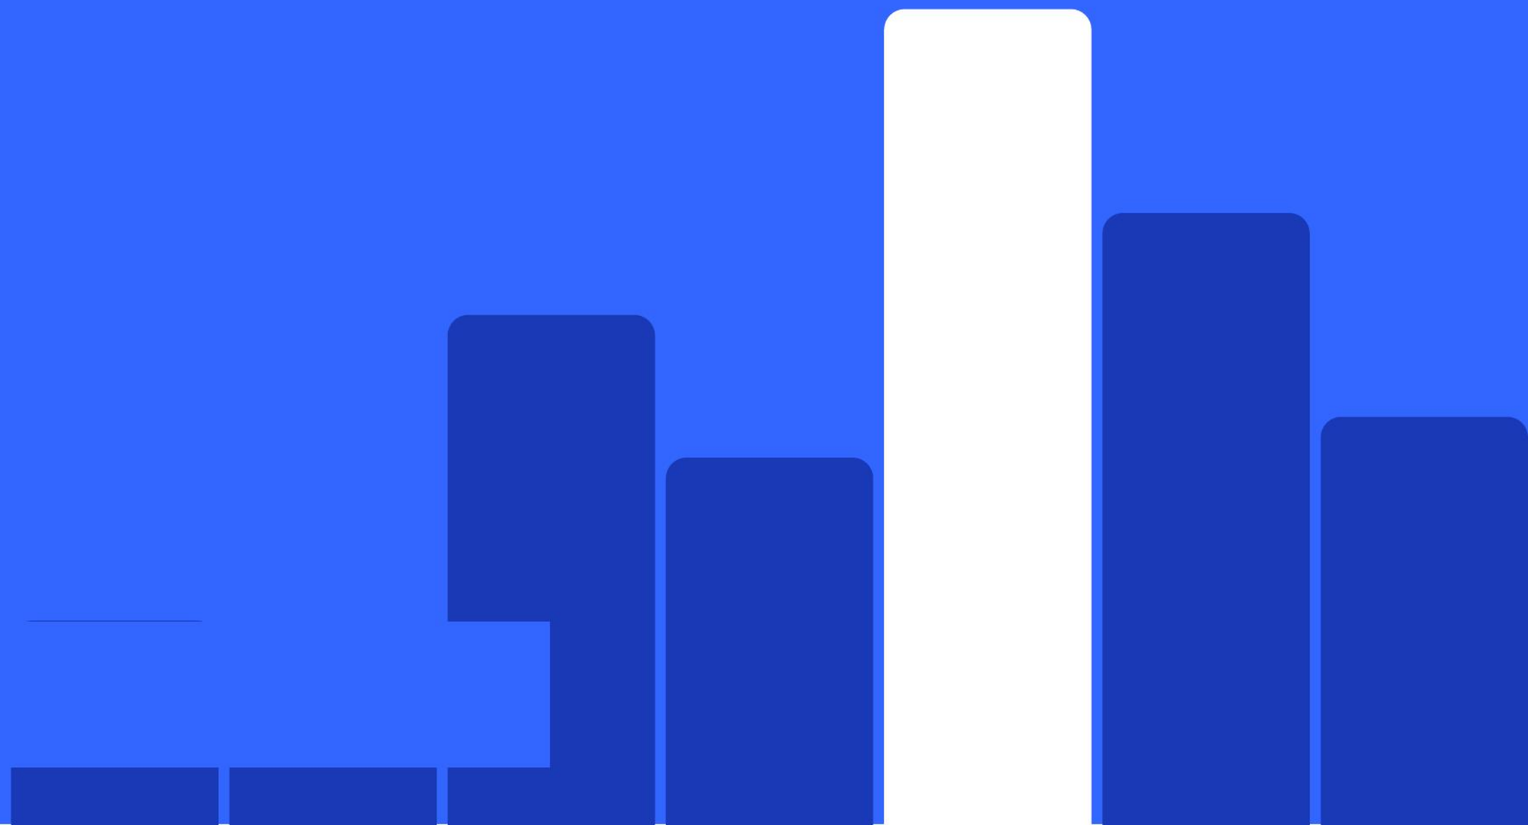
배송 지연 예측
데이터 분석 보고서



TEAM 1

목차

1. 문제 정의

2. 데이터 분석 EDA

3. 모델링 및 성능 평가

4. 데이터 탐색 및 인사이트

5. 결론 및 확장 가능성

문제 정의

온라인 글로벌 주문 환경에서는 다양한 요인에 의해
배송 지연이 발생할 수 있습니다.

배송 지연은 **고객 만족도 저하, 물류 비용 증가**로 이어지기에
배송 지연 가능성을 사전에 예측하는 것이 중요합니다.

본 프로젝트에서는 글로벌 주문 데이터를 활용해
배송 지연 여부를 **예측**하고자 합니다.



데이터 구성 및 특징

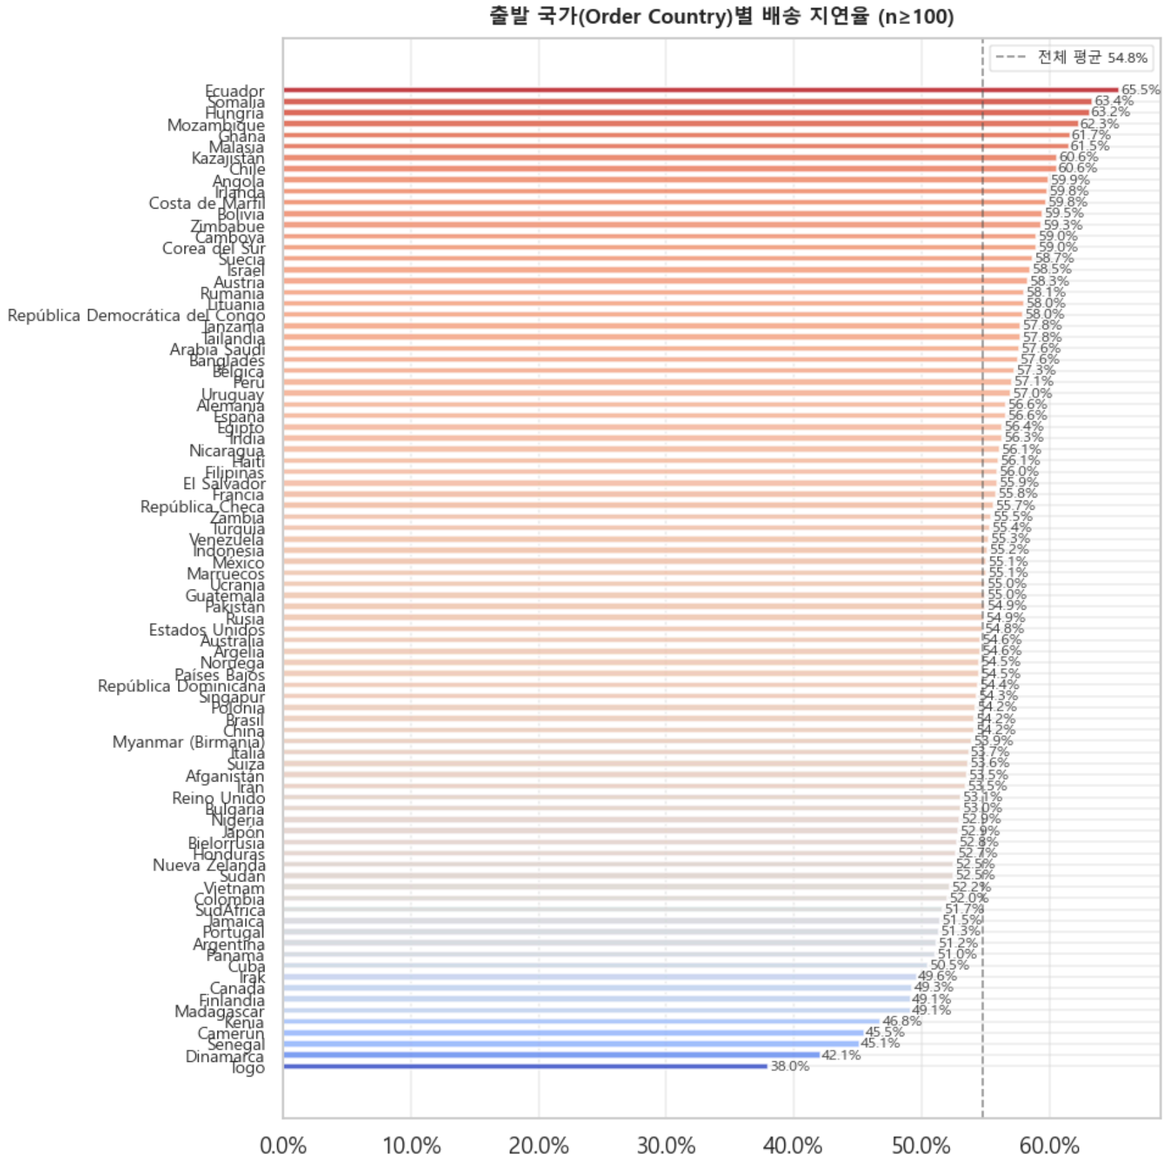
글로벌 e-커머스 기업의 2015~2018년 주문 데이터로, 총 144,415건의 거래 기록을 담고 있습니다.

고객 정보, 주문 위치, 상품 정보, 결제 방식, 할인율·수익 등 25개 피처가 제공되며, 결측치는 없습니다.

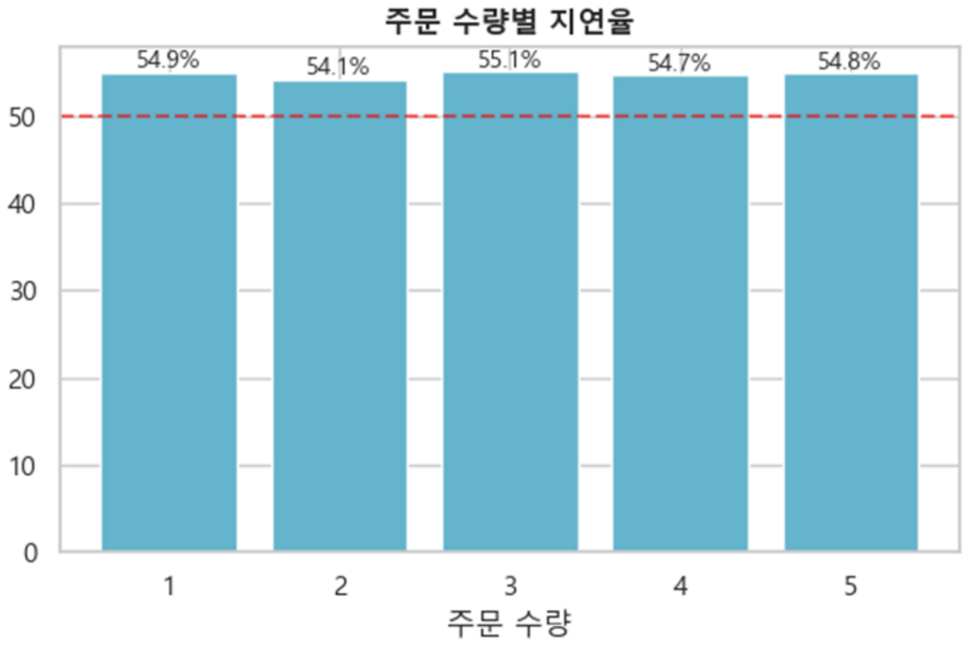
각 주문의 **배송 지연 위험 여부(Late_delivery_risk)**를 예측하는 이진 분류 문제로, 전체의 약 55%가 지연 위험 레이블로 분류되어 있습니다.



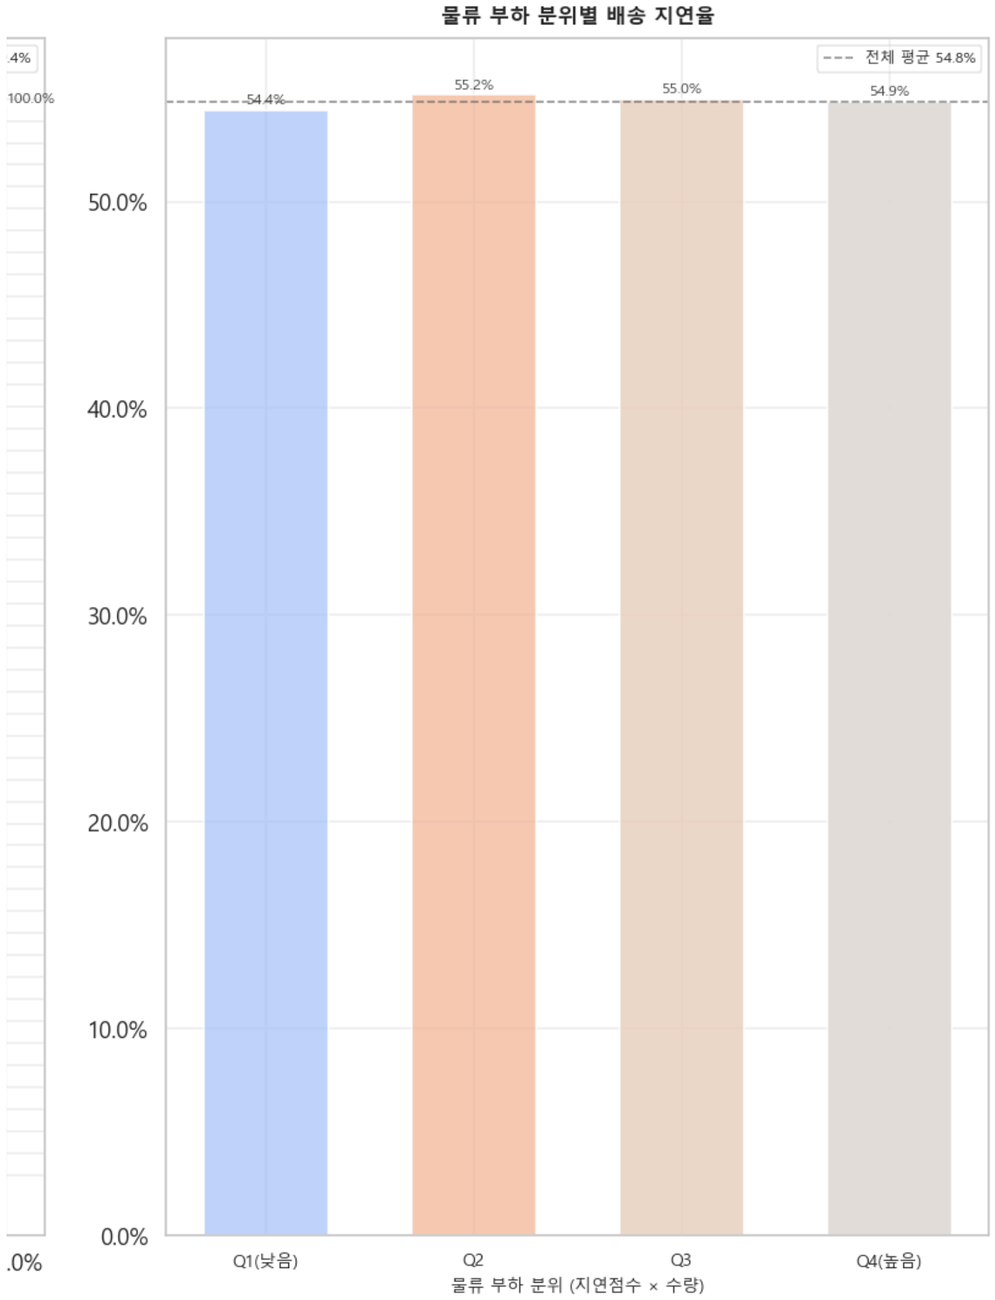
데이터 EDA 분석


출발 국가(Order Country)별 배송 지연율 (n≥100)
전체 평균 54.8%
Ecuador 65.5%
Somalia 63.4%
Hungría 63.2%
Mozambique 62.3%
Ghana 61.7%
Malasia 61.5%
Kazajistán 60.6%
Chile 60.6%
Angola 59.9%
Irlanda 59.8%
Costa de Marfil 59.8%
Bolivia 59.5%
Zimbabue 59.3%
Camboya 59.0%
Corea del Sur 59.0%
Suecia 58.7%
Israel 58.5%
Austria 58.3%
Rumania 58.1%
Lituania 58.0%
República Democrática del Congo 58.0%
Tanzania 57.8%
Tailandia 57.8%
Arabia Saudí 57.6%
Bangladés 57.6%
Bélgica 57.3%
Perú 57.1%
Uruguay 57.0%
Alemania 56.6%
España 56.6%
Egipto 56.4%
India 56.3%
Nicaragua 56.1%
Haití 56.1%
Filipinas 56.0%
El Salvador 55.9%
Francia 55.8%
República Checa 55.7%
Zambia 55.5%
Turquía 55.4%
Venezuela 55.3%
Indonesia 55.2%
México 55.1%
Marruecos 55.1%
Ucrania 55.0%
Guatemala 55.0%
Pakistán 54.9%
Rusia 54.9%
Estados Unidos 54.8%
Australia 54.6%
Argelia 54.6%
Noruega 54.5%
Países Bajos 54.5%
República Dominicana 54.4%
Singapur 54.3%
Polonia 54.2%
Brasil 54.2%
China 54.2%
Myanmar (Birmania) 53.9%
Italia 53.7%
Suiza 53.6%
Afganistán 53.5%
Irán 53.5%
Reino Unido 53.1%
Bulgaria 53.0%
Nigeria 52.9%
Japón 52.9%
Bielorrusia 52.8%
Honduras 52.7%
Nueva Zelanda 52.5%
Sudán 52.5%
Vietnam 52.2%
Colombia 52.0%
SudÁfrica 51.7%
Jamaica 51.5%
Portugal 51.3%
Argentina 51.2%
Panamá 51.0%
Cuba 50.5%
Irak 49.6%
Canadá 49.3%
Finlandia 49.1%
Madagascar 49.1%
Kenia 46.8%
Camerún 45.5%
Senegal 45.1%
Dinamarca 42.1%
Togo 38.0%
0.0%
10.0%
20.0%
30.0%
40.0%
50.0%
60.0%

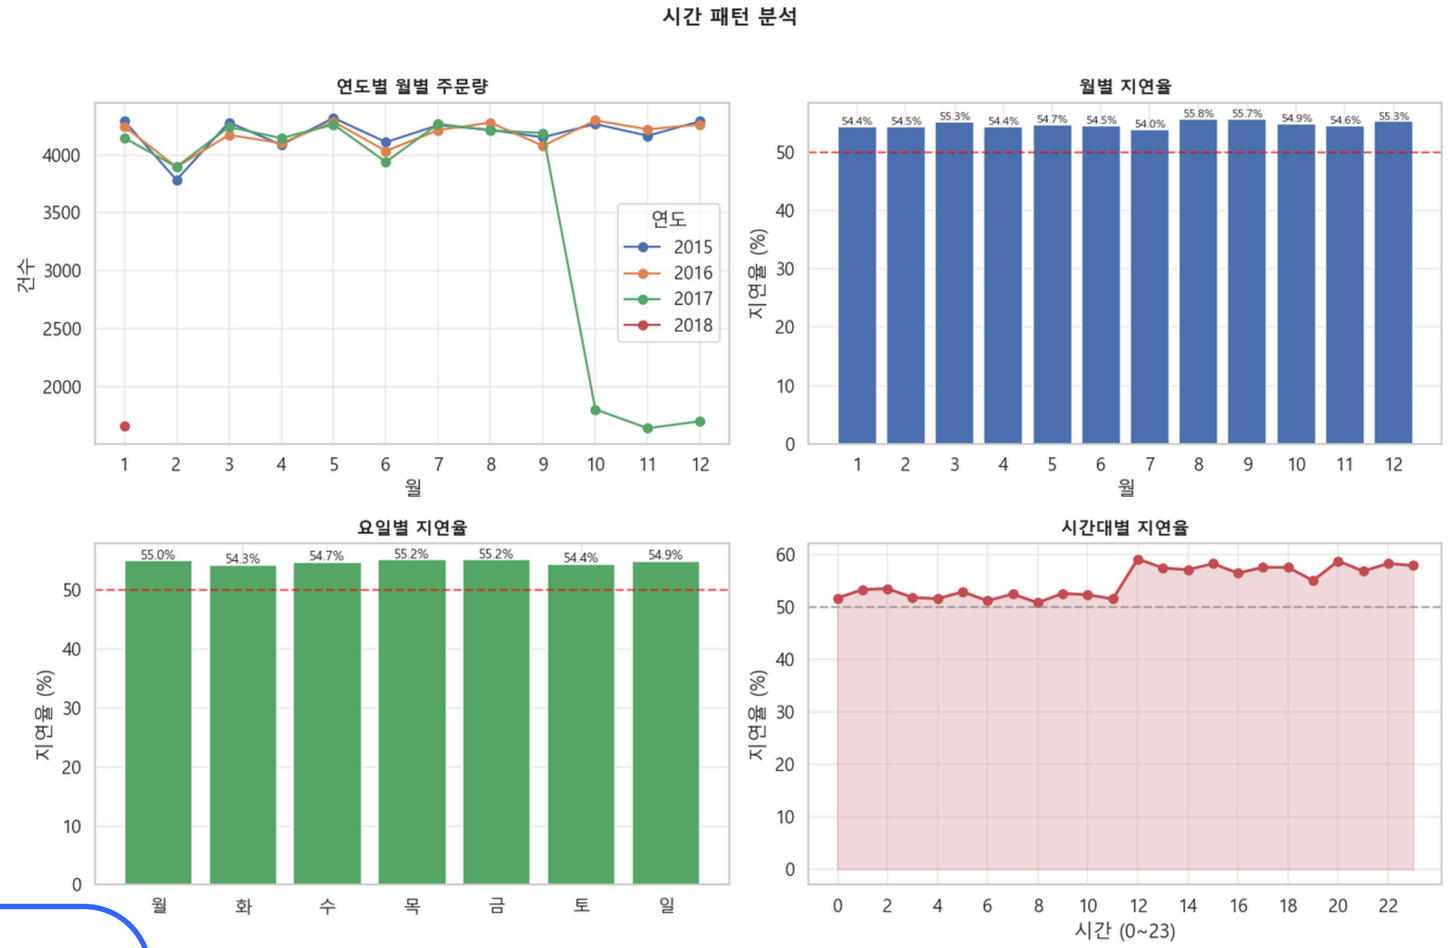
데이터 EDA 분석



Quantity 컬럼에서 주문 수량과 무관하게 고른 분포 확인
타겟 변수와 상관관계가 약하며, 타 변수와 결합하여도
유의적이지 않은 모습을 보이지 않았음.



데이터 EDA 분석

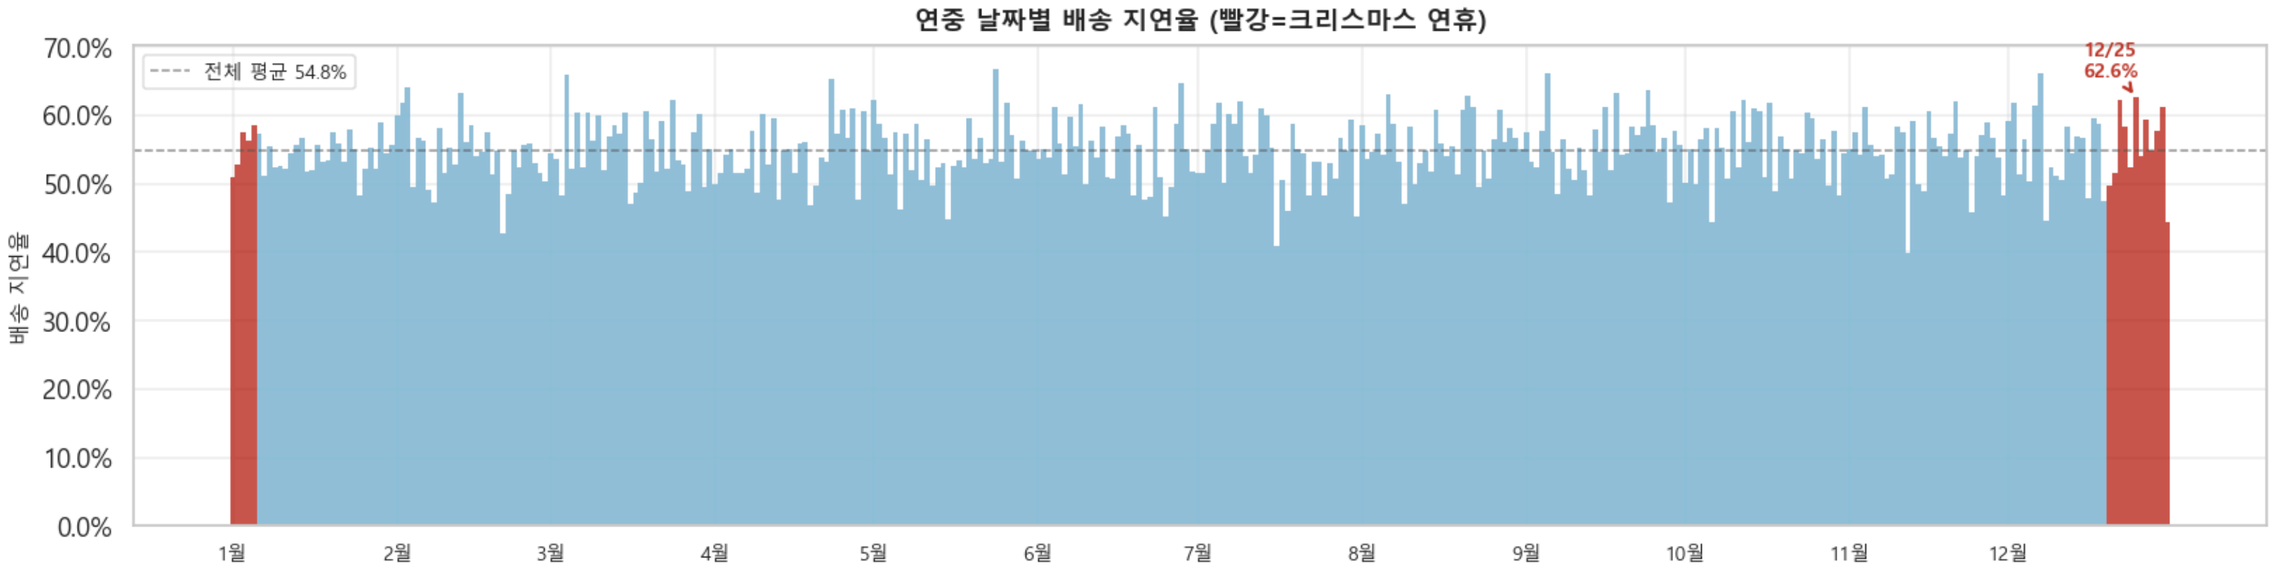


요일별/ 월별 상관관계는 낮음

12시를 기준으로 배송 **지연율**이 증가하는 양상을 보임

당일 출고가 불가능함에 따른 현상으로 추정

데이터 EDA 분석



크리스마스 : 크리스마스가 높을 것으로 인식했으나,
모든 날짜 중 가장 높은 것은 아니었고, 출발지와 도착지의
공통 휴일을 고려하기로 결정

전처리

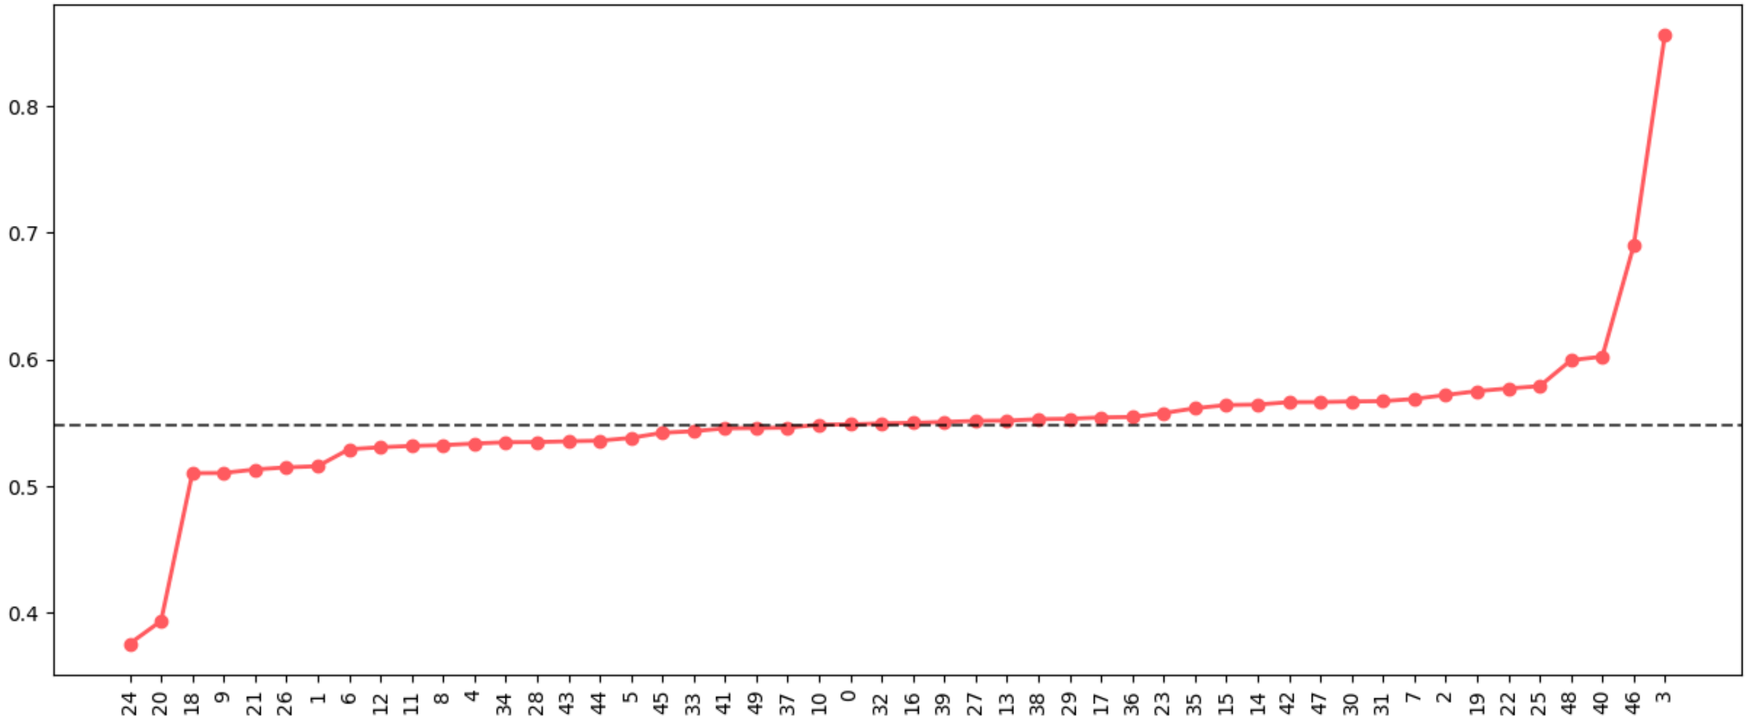
생성한 피쳐

- order date (DateOrder)을 나누어 7개 피쳐 생성

(order_year, order_month, order_day, order_hour, order_dayofyear, order_hour_sin, order_hour_cos)

- cat_orders_3d : 같은 카테고리에서 주문일 기준 3일간의 주문량 총합
- order_holiday, customer_holiday : 출발지, 배송지 공휴일
- same country/state/city : 출발지와 배송지가 같은지 출력하는 플래그
- geo_cluster_50 : 고객 위치 경위도 군집화

전처리



경위도 클러스터링(Size = 50, Seed = 42)

모델링 및 성능 평가

검증 전략: **StratifiedKFold (seed = 42)**

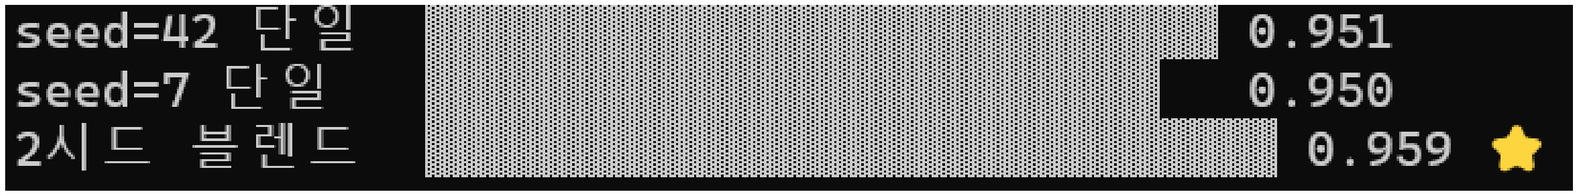
- 모든 폴드가 동일하게 분포 유지
- OOF 예측 144,415개로 단일 PR-AUC 산출
- 폴드 변동성 ±0.0025 (안정적)

모델 선정 근거: **LightGBM**

- 카테고리를 타깃 평균 순으로 정렬 후 최적 분할점
- Cardinality가 높음(Order City, Order State, ...)
- 과적합 방지 옵션(매 iteration 마다 검증 PR-AUC 측정. 150 round 동안 향상 없으면 학습 정지 + 가장 좋았던 시점의 모델 복원)
- XGBoost
  - LGBM 단독: 0.95955
  - XGB 단독: 0.95288 (낮음)
  - LGBM + XGB blend: 0.96040 (+0.001)
  - **LGBM × 2 시드: 0.96678 (+0.007)** ← 최고

모델링 및 성능 평가

모델	OOF PR-AUC	제출 파일
LightGBM 단일 (seed=42)	0.95123	submission_seed42.csv
LightGBM 단일 (seed=7)	0.95004	(저장 안 함)
LightGBM × 2 시드 rank-blend	0.95920 ⭐	submission_blend.csv
– 단일 대비 향상폭	+0.00797	



결론: 같은 모델, 같은 피처라도 fold split 시드만 바꿔서 2번 학습하고 blend 하면 OOF PR-AUC 0.008 안정적으로 향상
추가 비용 1번 학습의 학습으로도 큰 개선

데이터 탐색 및 인사이트

1 카테고리별 주문량 - 주문건수 | 배송지연률은 서로 유의미한 관계가 없다.

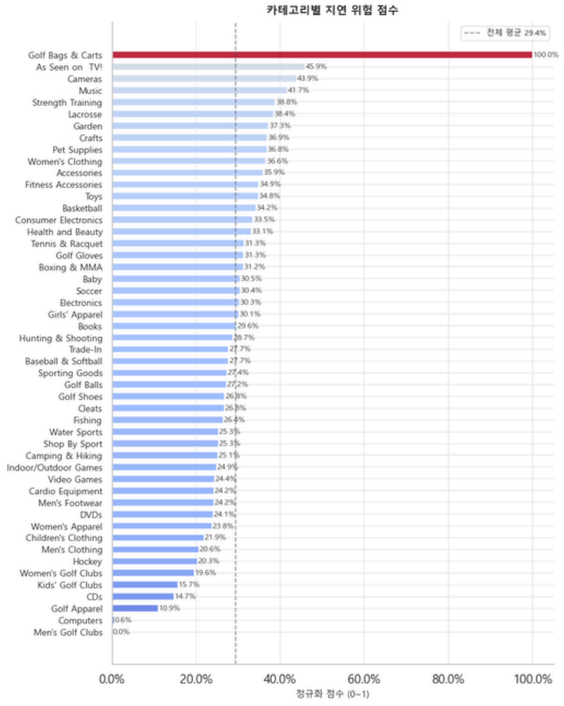
2 할인율 - 시기 - 주문량 | 배송 지연의 유의미한 관계가 없다.

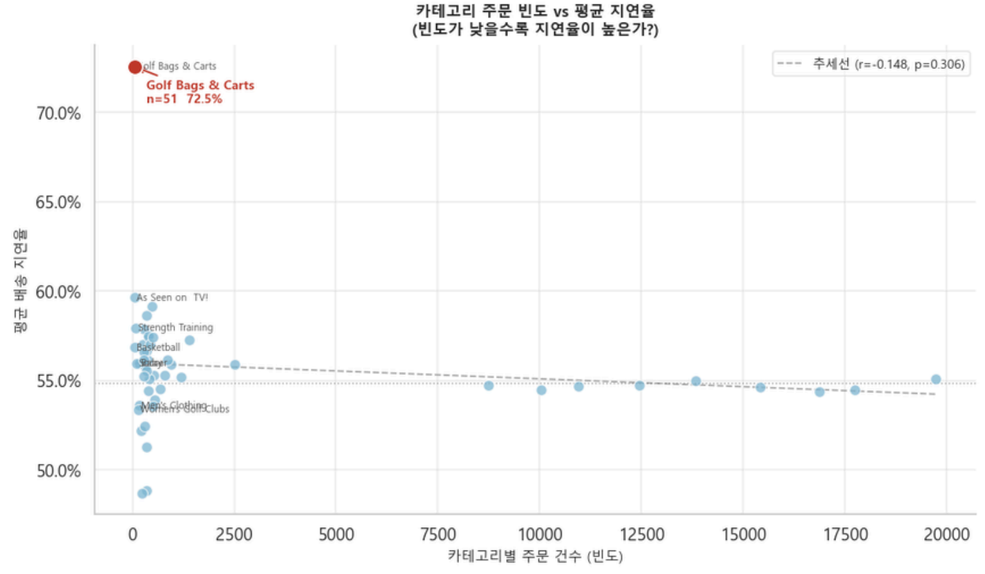
3 배송 지연은 지역별 물류 인프라 격차와 유의미한 상관관계를 보인다.

1 카테고리별 주문빈도와 배송지연률은 서로 유의미한 관계가 없다.

주요 발견 사항

- 특이 현상: **소수 표본 카테고리**(Golf 등)의 고지연 관측
- 검증 결과: 주문 빈도와 지연율 간 **상관관계 전무**
- **최종 결론**: 유통망 결함이 아닌 **데이터 부족**에 따른 통계적 편향의 의한 착시.
- 인사이트: Golf 등 일부 카테고리의 높은 지연율은 물류 시스템의 문제가 아닌 **표본 부족으로 인한 착시 현상**이므로, 해당 수치만을 근거로 한 인프라 개선 우선순위 선정은 지양해야 함

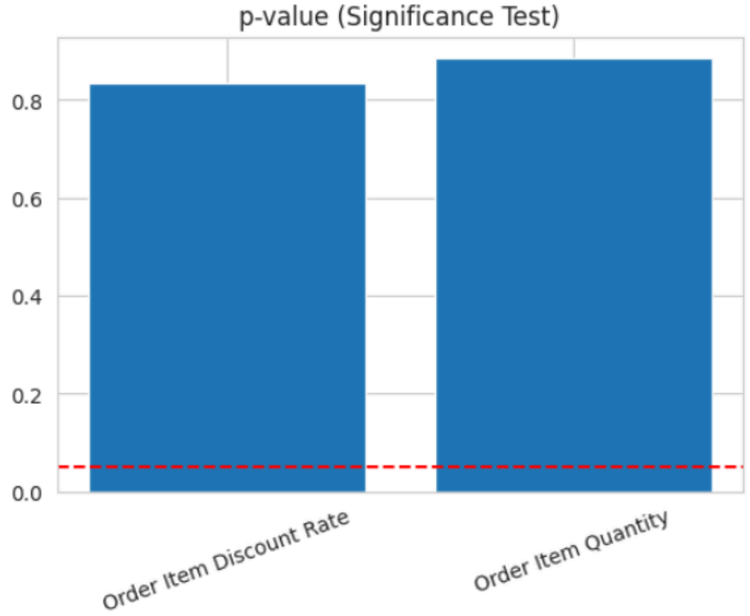


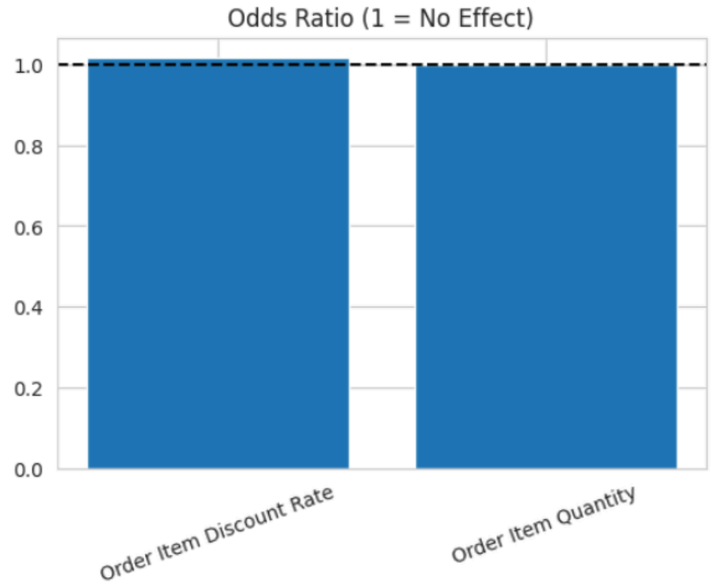


2 할인율, 주문시기, 주문량, 배송 지연간의 유의미한 관계가 없다.

주요 발견 사항

- 특이 현상: 할인율, 주문시기, 주문량 변화에도 배송 지연 리스크 분포에 큰 차이가 나타나지 않음
- 검증 결과: 할인율, 주문 시기, 주문량 모두 지연 리스크와의 상관관계가 낮은 것으로 확인됨
- **최종 결론**: 배송 지연은 주문 특성보다 **‘지역 인프라’**와 같은 구조적 요인의 영향을 더 크게 받음
- 인사이트: 물류 시스템은 주문량 증가나 할인 이벤트에 대해 비교적 안정적으로 운영되고 있으며, 향후 개선은 인프라 및 배송 네트워크 중심으로 접근할 필요 있음.

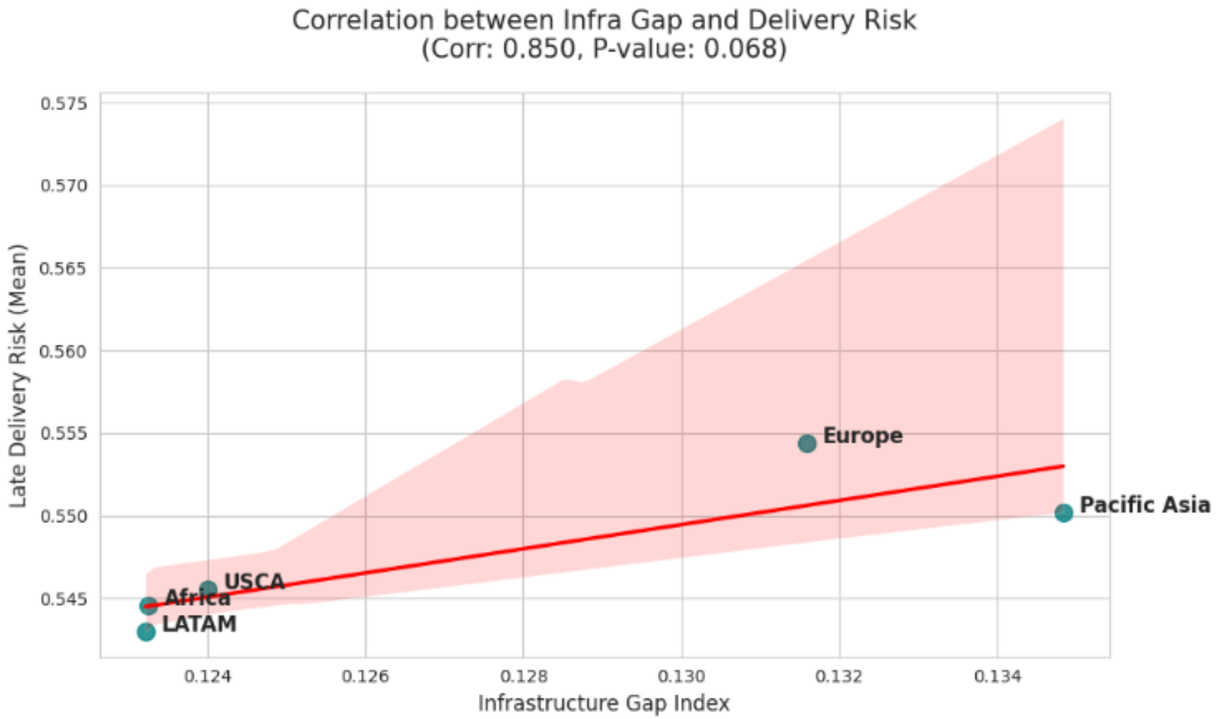




3 배송 지연은 지역별 물류 인프라 격차와 유의미한 상관관계를 보인다.

주요 발견 사항

- 특이 현상: 상품 종류보다 '목적지'가 지연의 핵심 변수이며, 특히 인프라 지수가 높은 유럽과 아시아 태평양 지역에 리스크가 집중됨.
- 검증 결과: 인프라 격차 지수는 통계적으로 매우 유의하며(P-value: 0.003), **인프라가 열약할수록 지연 리스크가 약 23.4배 증폭**됨.
- **최종 결론**: 배송 지연은 단순 거리가 아닌 통관 및 도로망 등 **'구조적 환경'**과 **'지역적 특성'**에 의해 결정됨.
- 인사이트: 지역별 인프라를 고려한 가변적 SLA 도입이 시급하며, 고위험 지역의 거점 확충 및 통관 파트너십 재편을 통해 시스템적 환경을 개선해야 함.



상관계수(Correlation): 0.8496
유의확률(P-value): 0.0684

결론 및 확장 가능성

- 배송 지연은 단일 요인(지역/시즌)이 아닌,
  인프라 격차와 지역별 구조적 환경이 결합된 **“복합 병목 현상”**
- **지리적 피처 + 시간 피처 + 할인율**을 결합하여 배송 리스크를 정량적 확률로 예측하는 모델 구축
- LightGBM + XGBoost **앙상블** 및 여러 **seed**로 편향을 줄인 안정적인 리스크 예측값 확보

- **초정밀 예측**: 기상, 공휴일, 항만 물동량 등 외부 API 연동을 통해 예측 환경의 변동성 최소화.
- **설명 가능한 운영**: XAI 기반 리포팅을 도입하여 현장 관리자의 의사결정 신뢰도 확보.
- **지능형 물류 시스템**: 예측 결과를 즉시 배송 스케줄링에 반영하는 실시간 대응 파이프라인(MLOps) 구축.

감사합니다!

