RAG를 통한 사전 프롬프트 재구성(RAPO) → VLM 피드백을 통한 사후 프롬프트 자율 수정(VISTA)

Beyond Simple Prompts
: RAG와 피드백 루프를 통한 Text-to-Video 고도화 (RAPO, VISTA)

- VISTA: A Test-Time Self-Improving Video Generation Agent
- The Devil is in the Prompts: Retrieval-Augmented Prompt Optimization for Text-to-Video Generation

서강대학교 미디어&엔터테인먼트학과 20241075 김주희

핵심 연구 과제:

AUTOMATED T2V PROMPT OPTIMIZATION

입력(Input)	사용자의 추상적이거나 간결한 원본 프롬프트 (Short/Simple Prompt)
출력(Output)	비디오 생성기의 시각적 완성도, 운동성, 일관성을 극대화하는 최적화된 상세 프롬프트 (Optimized Prompt)
문제의 본질	텍스트 모달리티와 고차원 시공간 비디오 생성 모델 간의 시맨틱 격차 해소

기존 연구의 한계

https://sgllm.sogang.ac.kr/dashboard/chat/40882/801b5caf-8307-475f-a9c8-9f3082a6721a

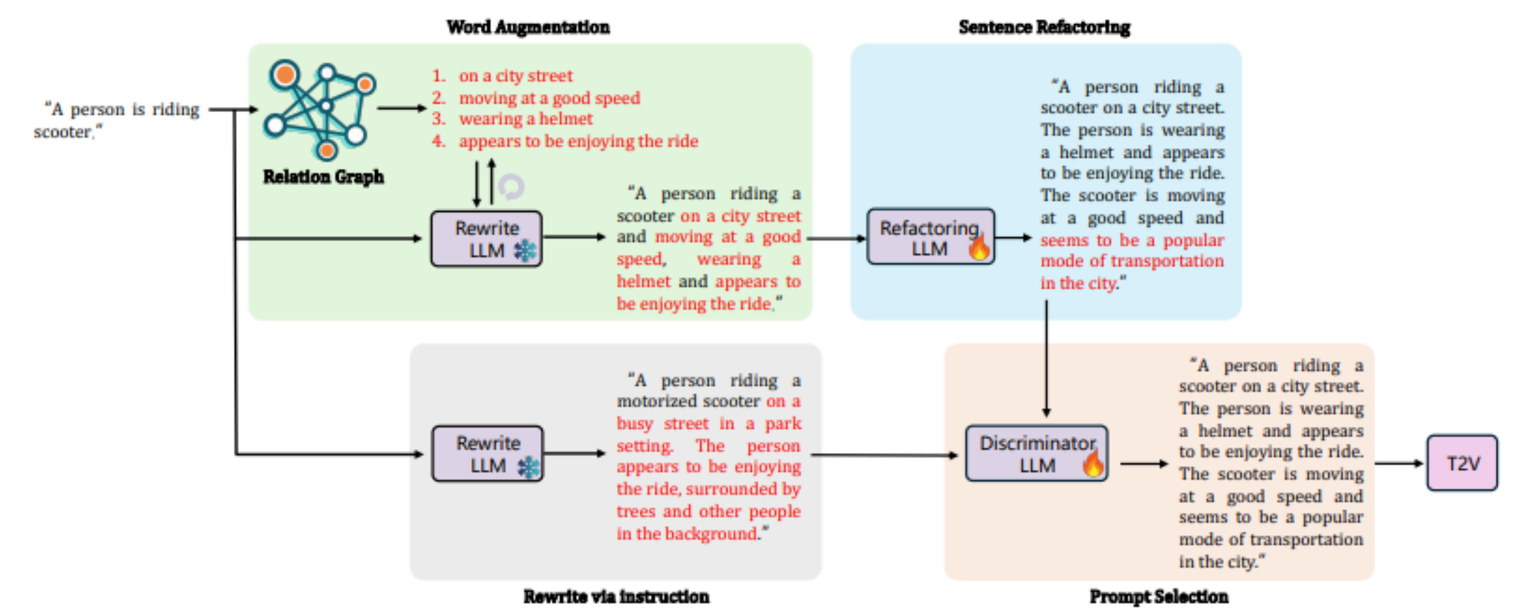
- **Single-shot LLM 재작성의 한계**: 비디오 모델이 무엇을 표현하기 어려워하는지 모른 채 텍스트만 한 번에 늘린다.
  길고 복잡해진 프롬프트가 오히려 성능을 떨어뜨리기도 한다.
- **결과 미확인 문제**: 생성된 영상을 보지 않고 프롬프트를 고정하기 때문에, 모션 왜곡이나 프레임 튐 같은 시각적 결함을 고칠 수 없다.

T2V 프롬프트 고도화는 **생성 전 지식 보강과 결과 기반 수정이** 함께할 때 완성된다.

→RAPO: 관계 그래프로 '모델이 잘 아는 표현'을 공급 / VISTA: 다중 에이전트 비평으로 '결과를 보고'

RAPO:

Retrieval-Augmented Prompt Optimization for Text-to-Video Generation



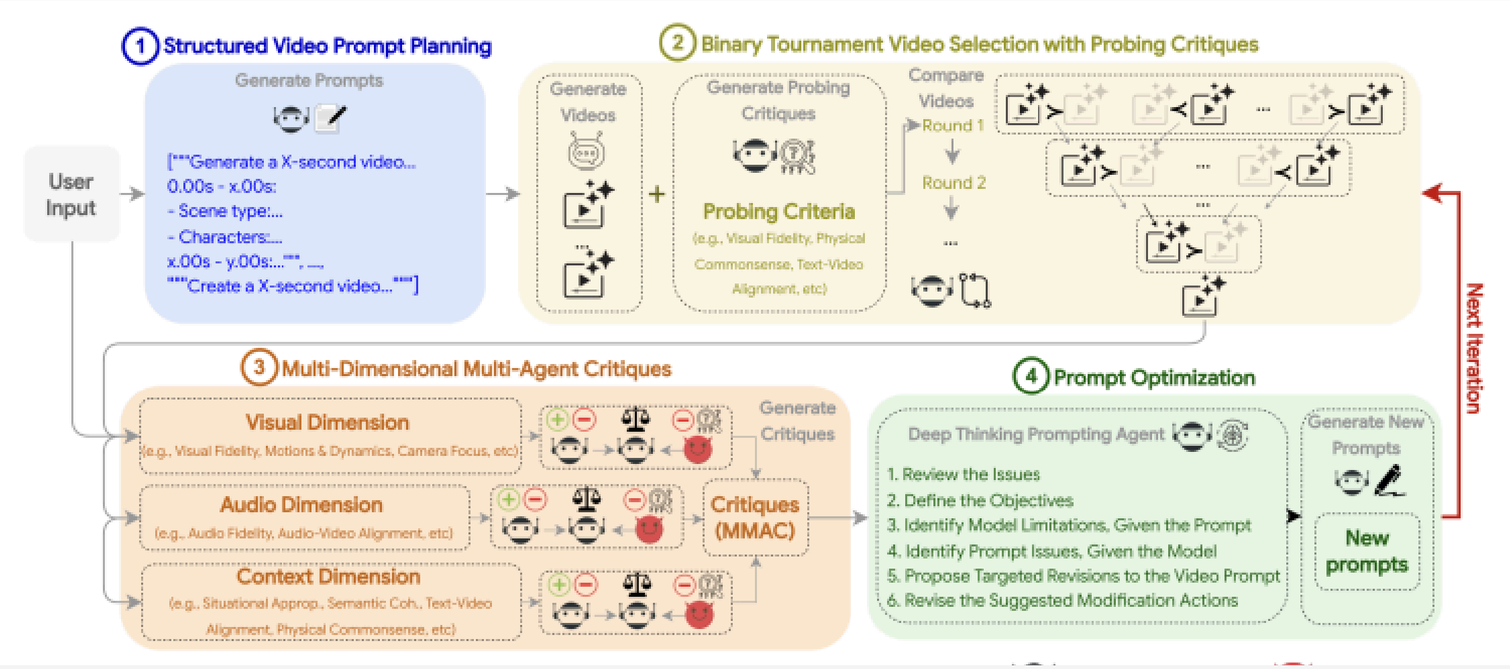
- 생성 전 개입: 텍스트 단계에서 모든 처리가 끝남
- 목표: 학습 데이터의 어휘, 문장 형식, 길이에 맞추기
- Refactoring LLM과 Discriminator LLM은 파인 튜닝 모델 (LLaMA 3.1 + LoRA)

① 단어 보강: 관계 그래프 검색 → 수식어 병합 → 문장 재구성 (Refactoring LLM)
② 지시문 재작성: LLM이 사용자 입력을 바로 재작성

→ Discriminator LLM이 두 결과 중 더 나은 프롬프트를 선택 → T2V 모델로 전달

VISTA:

A Test-Time Self-Improving Video Generation Agent



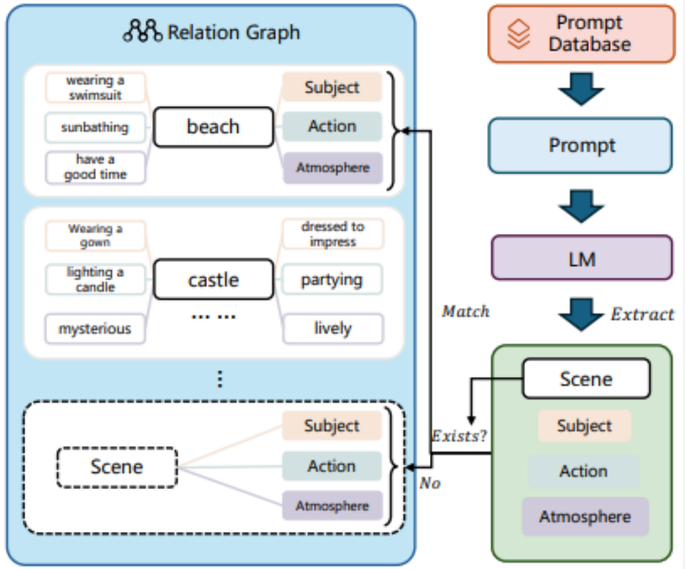
- 생성 후 개입: 결과 영상을 직접 보고 수정
- 별도 학습 없이 상용 모델에 적용 (Veo 3 + Gemini 2.5 Flash).

구조화 기획 (장면별 9개 속성) → 이진 토너먼트로 최고 영상 선택 → MMAC 삼항 비평(일반 +/적대 - 판사, 메타는 저울), 시각/음향/문맥 → DTPA 6단계 추론으로 프롬포트 수정 → 다음 반복

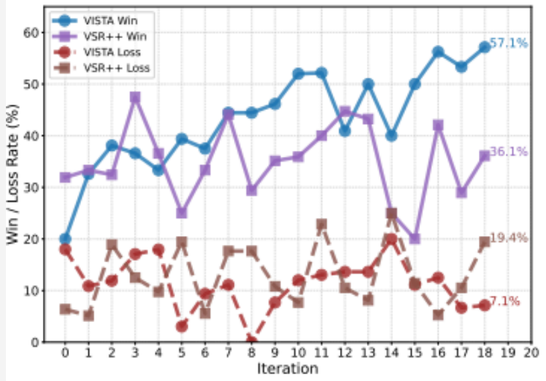
01 관계 그래프 기반의 '모델 친화적' 프롬프트 구축 (RAPO)

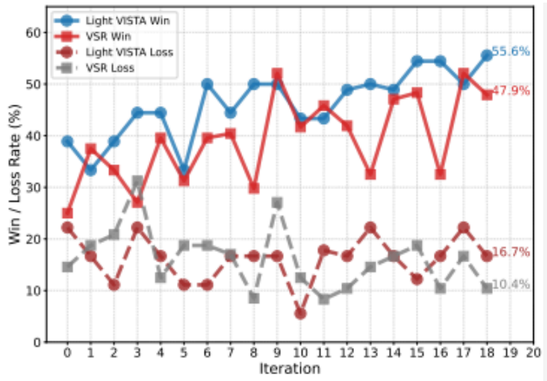
02 시각·음향·문맥 멀티모달 삼항 비평 체계 정립 (VISTA)

03 반복을 늘릴수록 안정적으로 개선될 가능성 확인 (VISTA)



비디오 구성 요소 간 상관관계를 그래프 구조로 사전에 구축하여,
프롬프트 재작성 시 어색한 어휘 조합을 방지하고 문맥적 완성도를 보장.





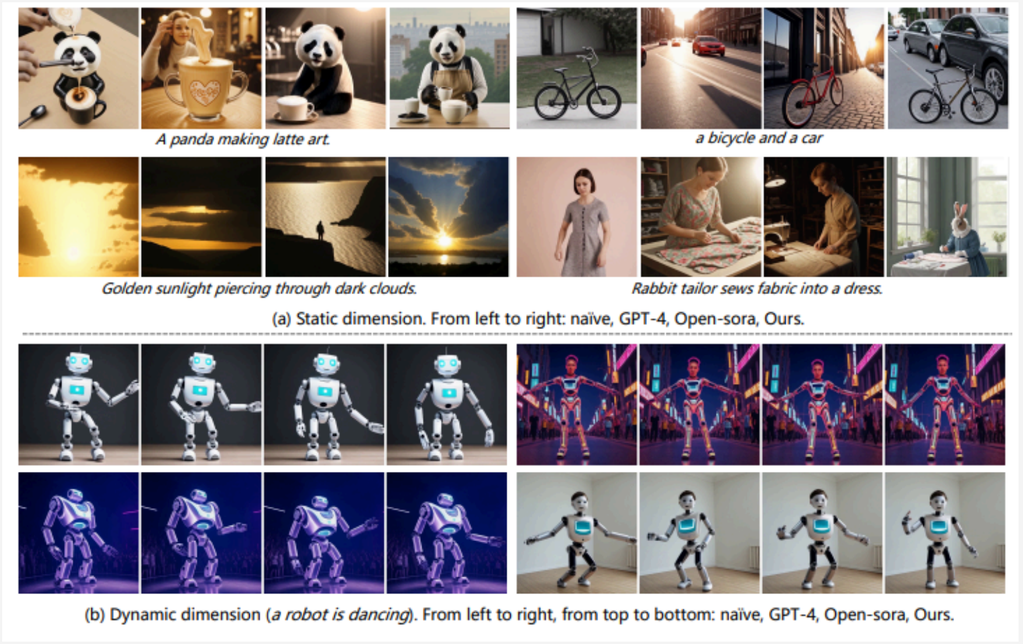
20회 반복 시 VSR++는 요동치며 36.1%에 머문 반면, VISTA는 57.1%까지 꾸준히 상승했다 (왼쪽, single-scene).
※ 오른쪽(multi-scene, 경량 VISTA vs VSR)은 격차가 더 작음 (55.6% vs 47.9%)

RAPO 성능 및 실험 분석

LaVie: 총점 80.89% → 82.38%, 다중 객체 37.71% → **64.86%**
Latte: 총점 77.03% → 79.97%, 다중 객체 29.55% → **52.78%**

Models	Total Score	temporal flickering	imaging quality	human action	object class	multiple objects	spatial relationship
LaVie	80.89%	96.62%	69.00%	95.80%	92.09%	37.71%	37.27%
LaVie-GPT4	79.69%	96.14%	70.27%	83.80%	88.73%	36.23%	50.55%
LaVie-Open-sora	79.75%	96.42%	70.42%	87.00%	91.29%	36.52%	54.37%
LaVie-Ours	**82.38%**	**96.86%**	**71.40%**	**96.80%**	**96.91%**	**64.86%**	**59.15%**
Latte	77.03%	97.10%	63.38%	88.40%	83.86%	29.55%	40.63%
Latte-GPT4	77.40%	97.52%	63.54%	85.80%	78.32%	27.73%	36.72%
Latte-Open-sora	77.23%	97.67%	64.19%	84.60%	83.60%	30.00%	35.12%
Latte-Ours	**79.97%**	**98.17%**	**66.72%**	**95.20%**	**96.47%**	**52.78%**	**41.31%**

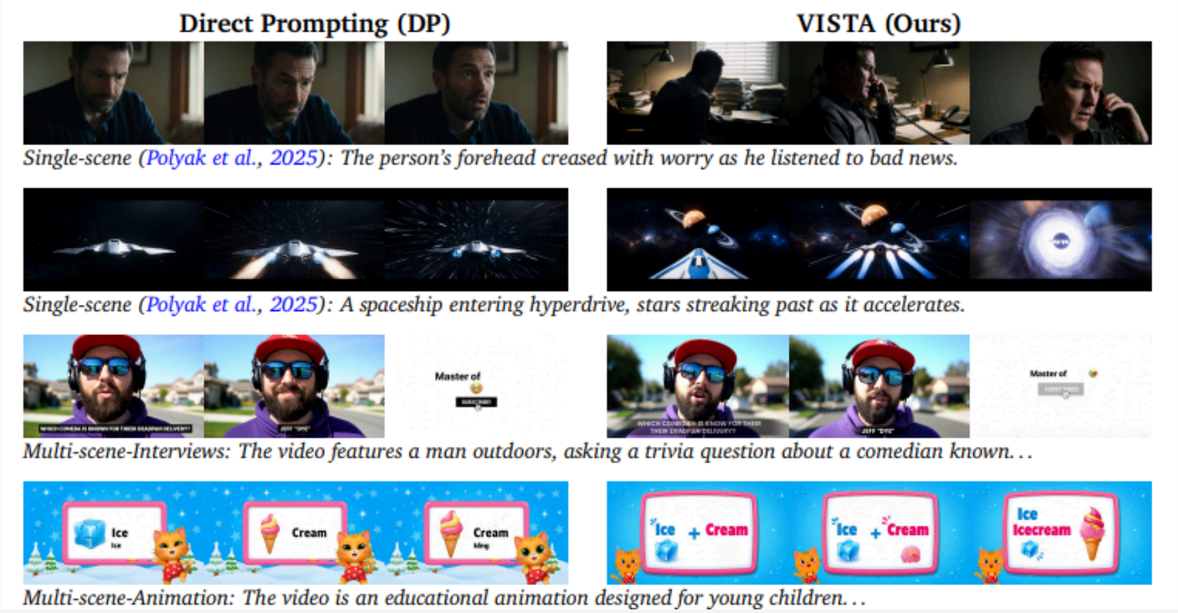
*길게 쓰면 손해: GPT-4로 재작성하면 LaVie 총점이 80.89% → 79.69%로 오히려 하락 (human action은 95.80% → 83.80%)
→ 프롬프트 길이가 학습 데이터 분포에 가까울 때 성능이 가장 높음



VISTA 성능 및 실험 분석

	Init	2	3	4	5
Single-scene	35.5	40.7	41.4	42.4	**45.9**
Multi-scene	37.8	39.4	38.4	43.7	**46.3**

- 반복할수록 상승: 최종 회차에서 최고 승률
- 베이스라인 대비 우위: VSR, VSR++, Rewrite, VPO와의 1:1 비교에서 전 회차 Δ > 0
- 인간 평가: 평가자의 **66.4%**가 VISTA 결과를 선호
- 약한 모델에서도 효과: Veo 2에서 15.0% → 23.8% (single), 27.6% → 33.3% (multi)
- 판사 구성의 중요성: 일반 판사만 쓰면 multi 승률이 17.2%로 붕괴, 적대 판사만 쓰면 18.8%에서 정체 → 두 판사를 결합해야 함



두 논문 비교 및 수치 결과

구분	**RAPO**	**VISTA**
개입 시점	생성 전	생성 후 (반복)
결과 영상 확인	X	O
학습 필요	학습 프롬프트 DB + 파인튜닝	불필요
적용 대상	학습 데이터를 아는 모델 (LaVie, Latte)	블랙박스 상용 모델 (Veo 3)
평가 방식	VBench 등 정량 벤치마크	MLLM 판정 + 인간 평가
오디오	X	O
비용	낮음	높음

※ 실험 모델과 평가 방식이 달라 두 논문의 수치는 직접 비교할 수 없음

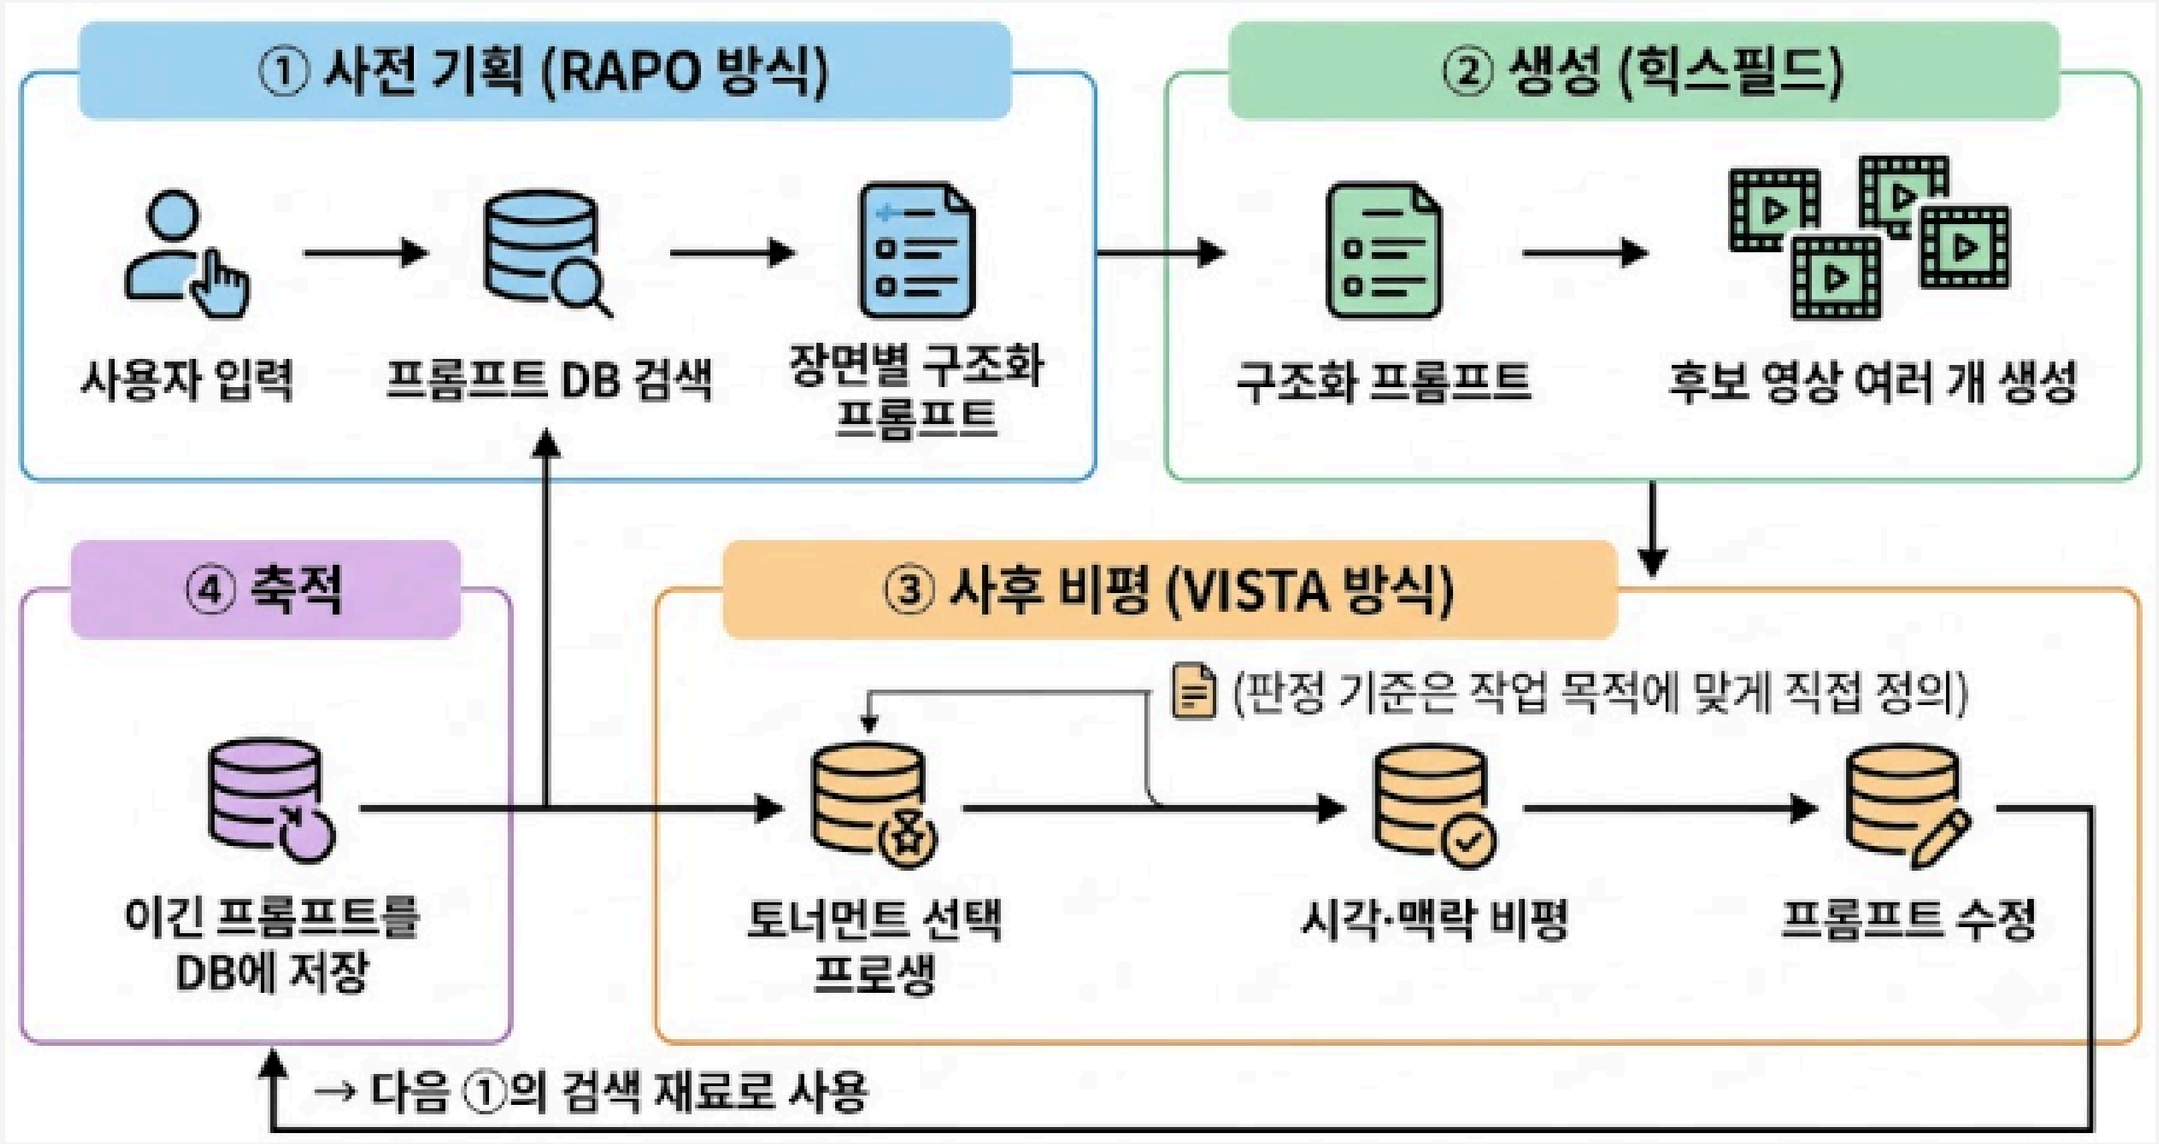
64.86% — RAPO 다중 객체 점수 (원래 37.71%)
66.4% — VISTA 인간 평가 선호율
28개 — VISTA 반복 1회당 생성 영상 수 (토큰 약 70만 개)
46% vs 93% — 같은 결과를 판정 모델만 바꿨을 때의 승률 (Gemini vs Qwen)

기존 베이스라인의 실패 원인

- **피드백 없음 (Rewrite, VPO):** 결과를 보지 않아서 물리 법칙 위배 같은 렌더링 오류를 인식하지 못함
- **피드백이 얕음 (VSR):** "매우 성공적"이라고 평가한 영상에서도 VISTA는 우주선 이동 방향 오류를 찾아냄. 반복할수록 프롬프트만 길어지고 원래 의도가 흐려짐

RAPO / VISTA의 한계

- **RAPO의 적용 범위:** 대상 모델의 학습 프롬프트 DB와 LLM 2개 파인튜닝이 필요해서, 학습 데이터가 비공개인 상용 모델에는 그대로 쓰기 어려움.
- **VISTA의 비용:** 반복 1회당 영상 약 28개, 토큰 약 70만 개 소모.
- **MLLM 평가의 신뢰성:** 판정 모델에 따라 승률이 45.9% ↔ 93.3%로 달라짐. 최적화와 판정을 모두 Gemini가 맡아 자기 선호 편향 가능성도 있음.


① 사전 기획 (RAPO 방식)
사용자 입력
프롬프트 DB 검색
장면별 구조화 프롬프트
② 생성 (힉스필드)
구조화 프롬프트
후보 영상 여러 개 생성
③ 사후 비평 (VISTA 방식)
(판정 기준은 작업 목적에 맞게 직접 정의)
토너먼트 선택 프로샘
시각·맥락 비평
프롬프트 수정
④ 축적
이긴 프롬프트를 DB에 저장
→ 다음 ①의 검색 재료로 사용