Search Arena와 ShareChat 논문 발표

실제 사용자는 AI를 어떻게 쓰는가

서강대학교 미디어&엔터테인먼트학과 20241075 김주희

오늘의 순서

INDEX

01 메타태스크와 결론

02 Search Arena

03 ShareChat

04 두 논문 비교

05 Agenda

오늘은 세 가지 질문에 답합니다

Q1

사용자는 어떤 답을 좋아하는가?

Search Arena

Q2

서비스마다 사용 방식은 어떻게 다른가?

ShareChat

Q3

두 데이터는 무엇을 보여주고 놓치는가?

두 논문 비교

실제 사용은 벤치마크보다 훨씬 다양하다

0.29 vs 0.27

맞는 인용 vs 무관한 인용

사용자는 인용의 정확성을
잘 구분하지 못합니다

63.3%

Perplexity의 정보 찾기 비중

서비스마다 사용자가
맡기는 일이 다릅니다

67~88%

요청의 완전 해결 비율

서비스별로 해결 정도가 다릅니다

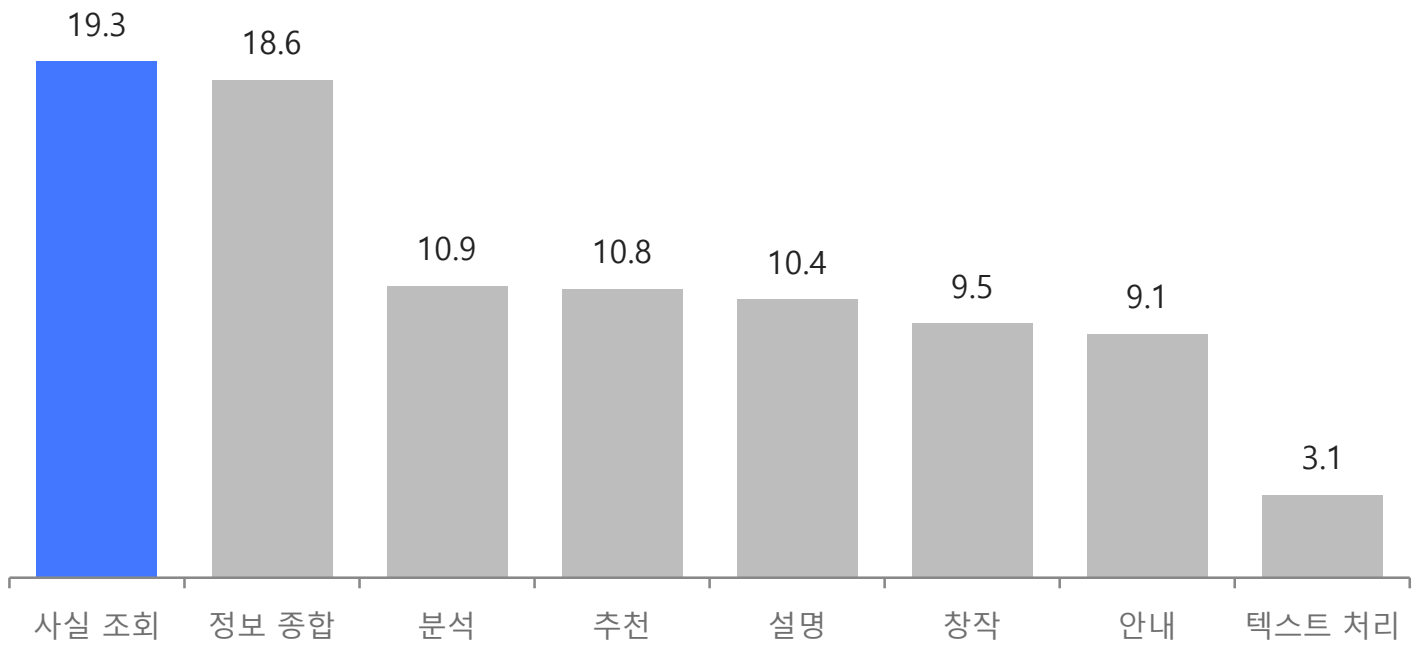
기존 평가셋은 실제 검색 사용을 담지 못했다

	대화 수	언어	멀티턴	평가 기준
SimpleQA	4,326	1	X	짧은 정답
BrowseComp	1,266	1	X	짧은 정답
Search Arena	**24,069**	**71**	**O**	**사용자 선호**

Miroyan et al., Search Arena (ICLR 2026) Table 1, p.2

Search Arena · 사용자 의도

검색 질문 중 사실 조회는 5분의 1이다



19.3%

사실 조회 비율

나머지는 종합, 분석, 추천처럼
더 복합적인 요청입니다

Search Arena Fig. 1, p.2 · Other 제외 · GPT-4.1 분류, Cohen's κ=0.812

사용자 선호는 정답이 아니라 만족의 신호다

1

쌍대 투표

익명의 두 답변을 비교

2

Bradley-Terry

모델 강도와 특성 계수 추정

3

상관분석

인과가 아닌 관련성만 해석

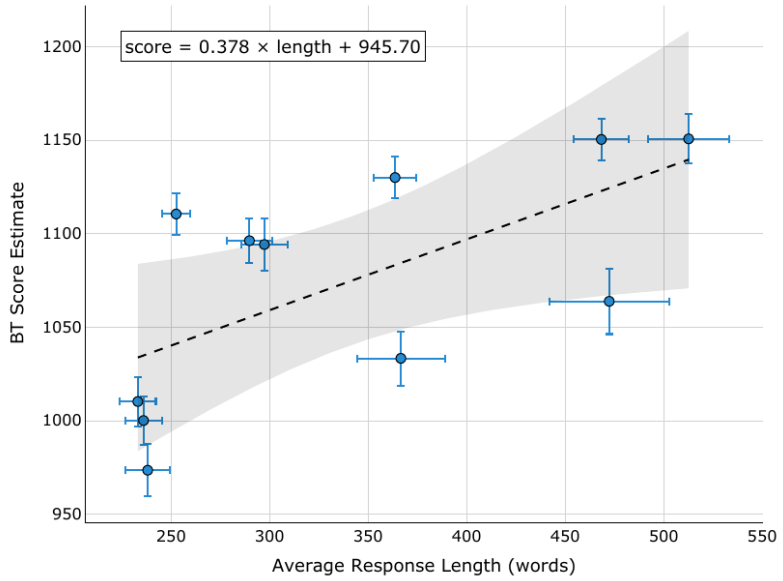
68%

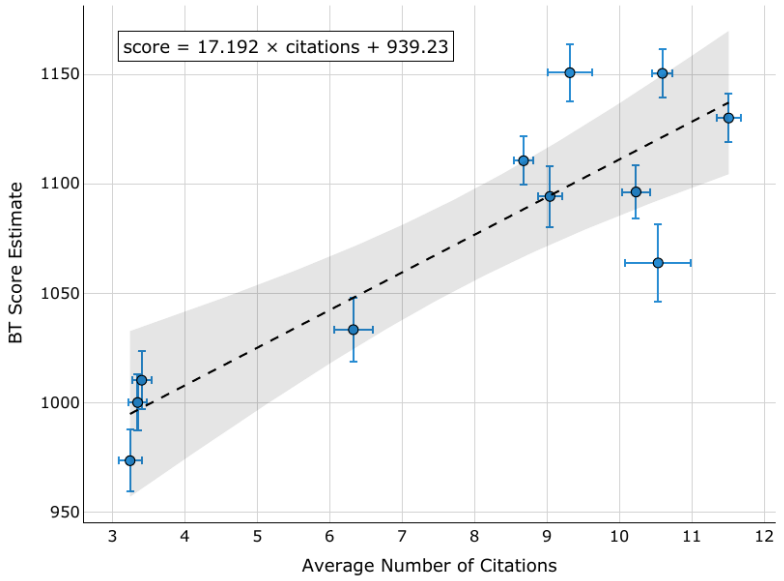
전문가-사용자 일치율

무작위 기준 50%보다 높지만,
주관성이 남아 있습니다

Search Arena Section 3, pp.4-5 · 전문가 3명, 100개 표본, 동점 제외

사용자는 길고 인용이 많은 답을 선호한다





0.334

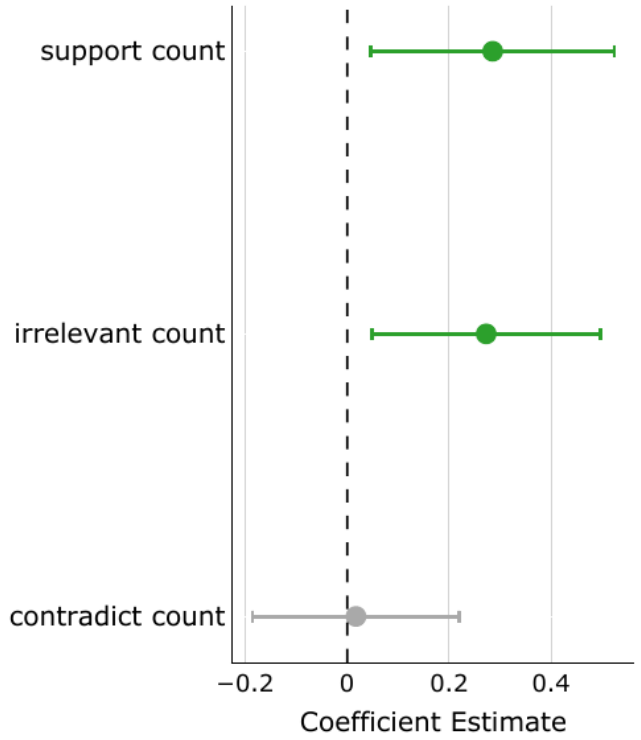
답변 길이 β · 길수록 선호 경향

0.209

인용 수 β · 많을수록 선호 경향

Search Arena Fig. 4, p.6, Section 3.1-3.2

사용자는 맞는 인용과 무관한 인용을 구분하지 못한다



0.29 vs 0.27

지지 인용 vs 무관한 인용의 계수

인용의 정확성보다 인용이 있다는
사실 자체가 영향을 줄 수 있습니다

Search Arena Fig. 6 Right, p.7 · 의도별 약 100개 대화, 수집 780개(p.34) · 모순 인용은 유의하지 않음

사람의 평가: 검색의 효과는 질문마다 다르다

	대결 수	검색 선호	비검색 선호	동점	p값
Text Arena	544	26%	28%	**45%**	0.244
Search Arena	315	**40%**	29%	31%	**0.009**

사실 조회

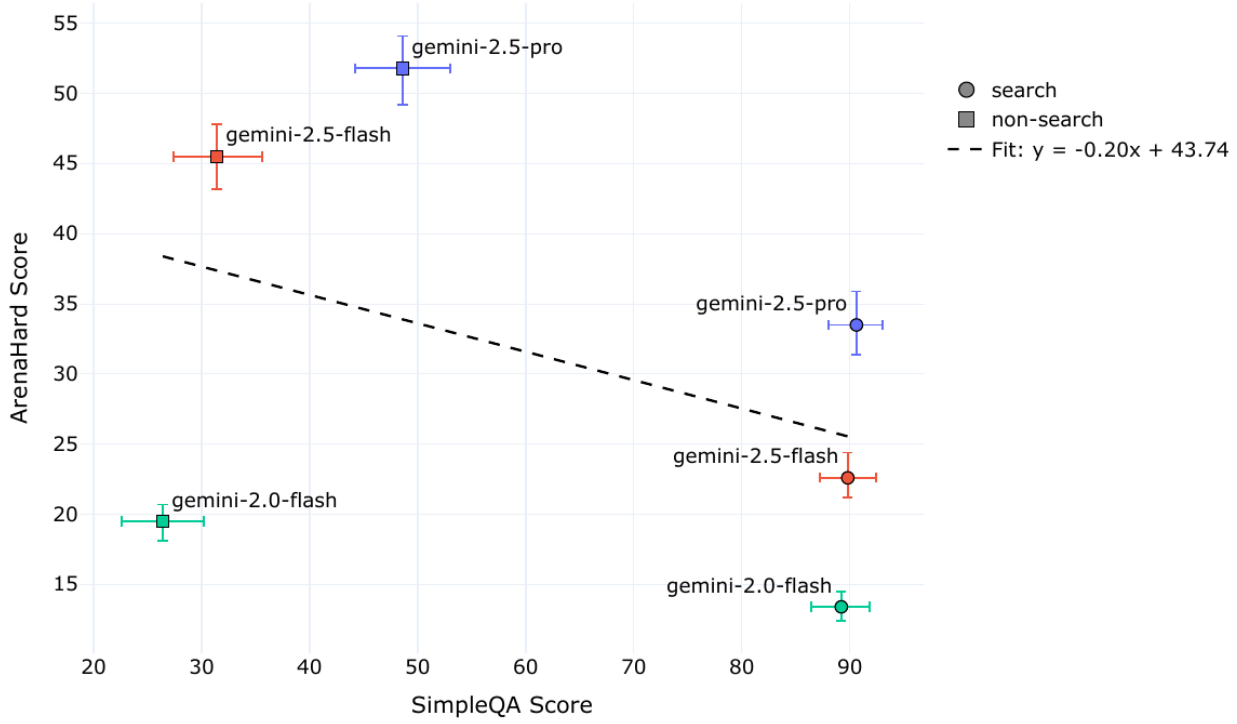
두 환경 모두 검색이 유리
Text p=0.012 · Search p=0.000058

텍스트 처리

Text Arena에서 비검색 쪽이 유리한 경향
p=0.077

Search Arena Section 3.3, Fig. 8, pp.8-9 · Search Arena에서는 비검색 모델의 상대가 여러 검색 모델이라 직접 비교에 주의

시험 점수: 검색의 효과는 과제마다 다르다



SimpleQA ↑

사실 검색에는 검색이 도움

ArenaHard ↓

어려운 시험에서는 비검색이 높음

Search Arena Appendix F, Fig. F.2, pp.35-37 · Gemini 검색 유무 비교

투표는 정답이 아니라 선호다

01

객관적 지표

사실성과 인용-주장 일치도를
함께 측정

02

오프라인 평가

사람의 선호를 근사하는
자동 평가 구축

03

검색 정책

언제 검색하고
내부 지식에 의존할지 결정

ShareChat은 더 길고 깊은 실제 대화를 담았다

	대화 수	평균 턴	답변 평균 토큰	언어
WildChat	3,199,860	1.61	519.73	76
LMSYS-Chat-1M	1,000,000	2.02	215.71	65
ShareChat	**142,808**	**4.62**	**1,115.30**	**95**

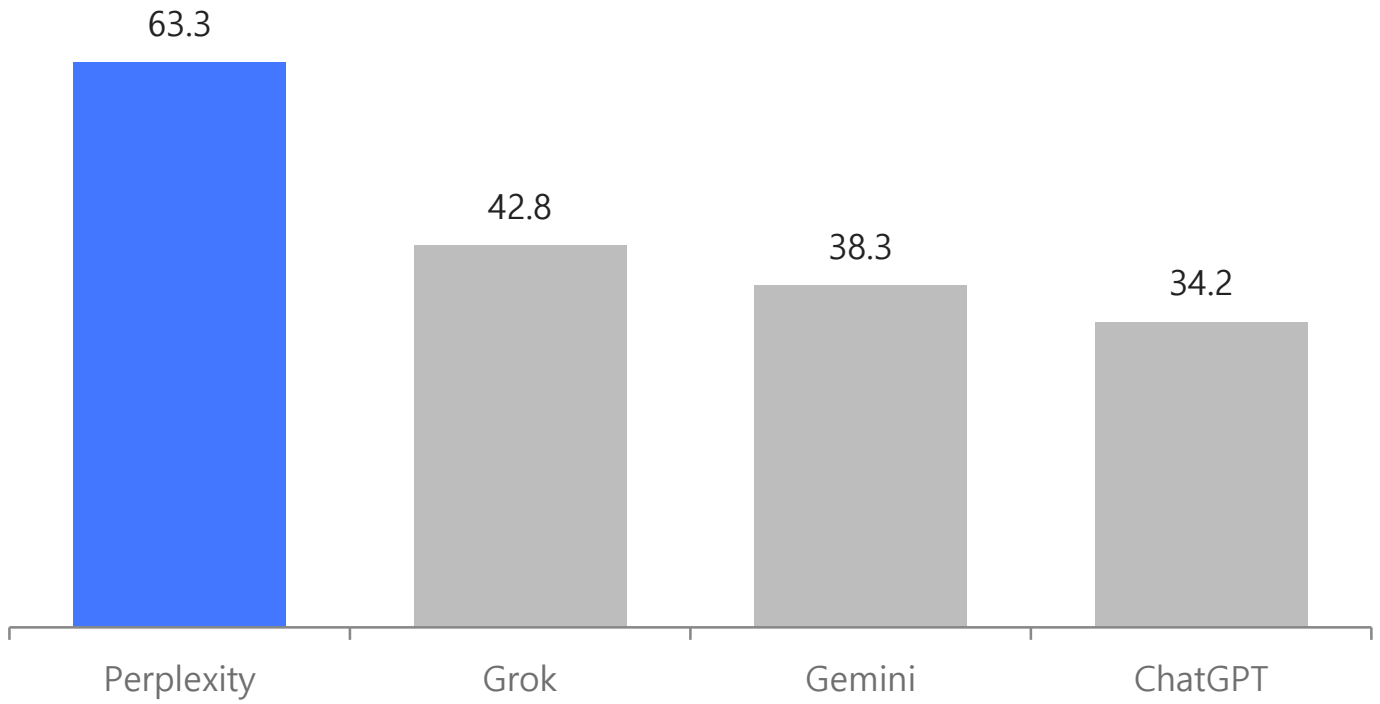
Yan et al., ShareChat (arXiv 2512.17843v4) Table 1, p.2 · 대화는 2023년 4월~2025년 10월, 공유 URL에서 수집

서비스마다 남는 정보가 다르다

서비스	대화 수	출처	추론 기록	턴별 시간	모델 버전
ChatGPT	102,740	-	-	O	O
Perplexity	17,305	O	-	-	-
Grok	14,415	O	O	O	O
Gemini	7,402	-	-	-	O
Claude	946	-	O	-	-

ShareChat Table 1-2, pp.2-3 · O는 해당 정보를 데이터로 확보한 경우

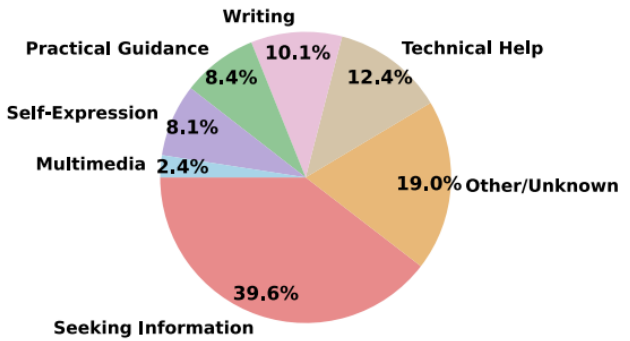
사용자는 서비스마다 다른 일을 맡긴다



39.6%

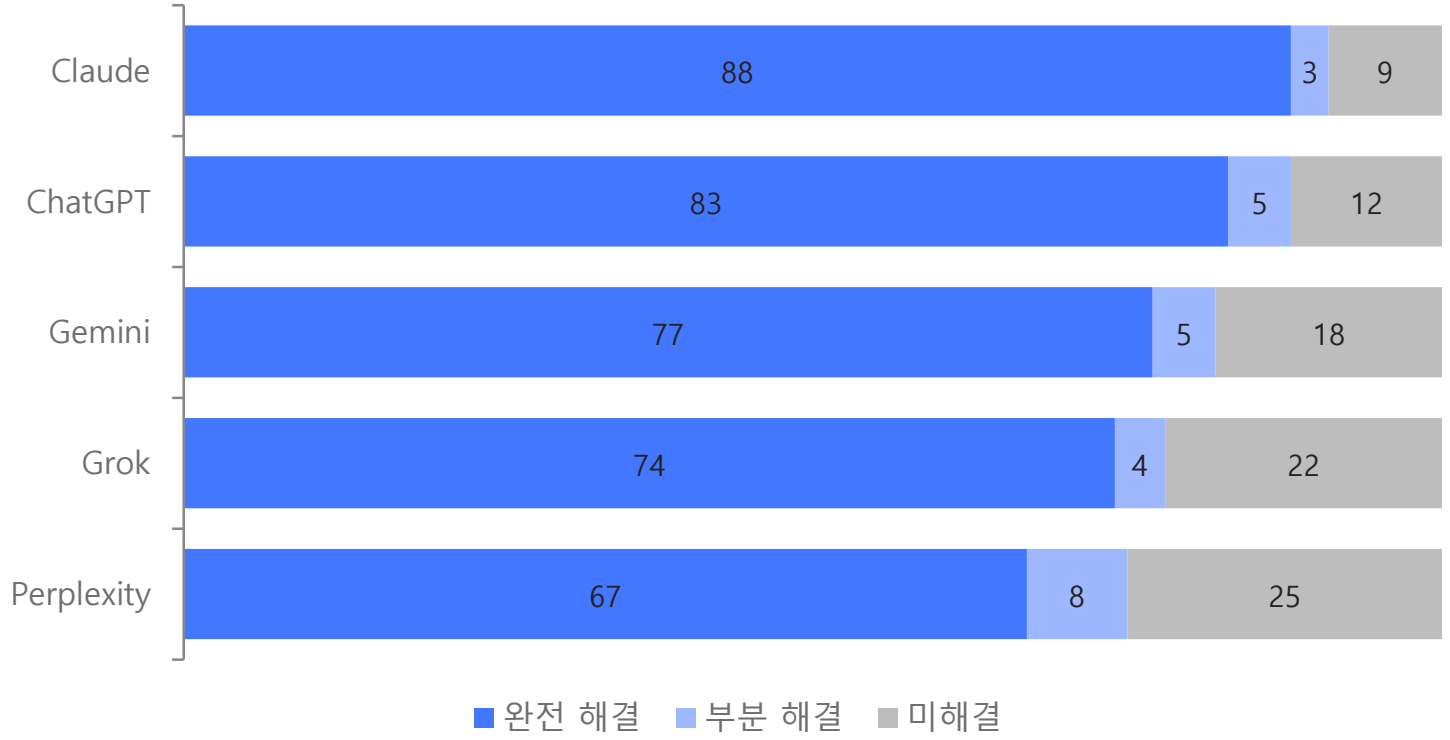
평균 정보 찾기 비중

Perplexity는 63.3%로 가장 높습니다



ShareChat Section 3.3, Fig. 3, Fig. 7 · Llama-3.1-8B 분류, 사람 라벨 대비 정확도 82.0%

요청의 완전 해결 비율은 서비스마다 다르다



88% vs 67%

Claude vs Perplexity

완전 해결 비율의
최고와 최저입니다

ShareChat Fig. 4, p.6 · Qwen3-8B 판정, 합의 라벨 대비 정확도 87.40% · Claude 표본은 작음 · Perplexity 답은 중간 단계일 수 있음

Grok은 X에, Perplexity는 여러 출처에 기댄다

	Grok	Perplexity
출처 포함 대화	8,242개 (57.18%)	8,545개 (49.38%)
가장 많은 출처	X 40,624건	Wikipedia 2,919건
다음 출처	Wikipedia 12,507건	Reddit 1,642건, NIH 1,339건
대화당 출처 수	대체로 5개 미만	대개 1~20개
최대 출처 수	83개	1,059개

ShareChat Section 4.2, Appendix A.7

대화가 길어질수록 속도 변화는 정반대다

지표	ChatGPT	Grok
평균 응답 시간	18.4초	24.6초
사용자 평균 응답 시간	1,580초	931초
턴과 응답 시간의 상관	ρ = -0.427 (빨라짐)	ρ = 0.254 (느려짐)
답변 길이와 사용자 시간	r = 0.034	r = 0.021

ShareChat Section 4.3 · 상위 1% 이상 제거 · ChatGPT 기간에는 모델 업그레이드 4회가 섞여 있음

ShareChat은 공유된 대화만 보여준다

01

선택 편향

사용자가 공유할 대화를
직접 고름

02

서비스 불균형

ChatGPT 70% 이상,
Claude 1% 미만

03

LLM 판정

사람 검증은 영어 대화 중심

ShareChat Limitations, p.9

Search Arena는 선호를, ShareChat은 서비스 맥락을 본다

	Search Arena	ShareChat
핵심 질문	어떤 답을 선호하는가	서비스마다 어떻게 쓰는가
수집 방식	비교 플랫폼의 대화와 투표	공개 공유 URL
규모	대화 24,069개, 투표 12,652개	대화 142,808개, 660,293턴
강점	사용자의 직접 평가	서비스 고유 정보와 시간
한계	선호는 정답이 아님	공유된 대화만 포함

Search Arena Table 1, Section 5 · ShareChat Table 1, Limitations

입장마다 읽어야 할 결과가 다르다

입장	논문 근거	가설	제안
사용자	무관한 인용 β=0.27	인용을 보고 과신	근거 강도 표시
서비스	Perplexity 정보 찾기 63.3%	모든 사용자를 같게 설계	목적별 기능 설계

Agenda

논의점

평가 기준

선호와 정답을 어떻게 함께 평가할까?

데이터 편향

공유된 대화의 편향을 어떻게 줄일까?

서비스 평가

서비스 목적에 맞는 평가는 무엇일까?

데이터 결합

두 데이터를 함께 쓰면 무엇을 볼 수 있을까?

실제 사용자는 AI를 어떻게 쓰는가

THANK YOU