복합 태스크에서의 MAS 실패 원인 분석과 AI 카드뉴스 생성 아키텍처

More Agents, Better Results?
: Multi-Agent LLM의 협력과 실패

서강대학교 미디어&엔터테인먼트학과 20241075 김주희

MAIN CLAIM

복합 태스크에서 MAS의 성능 향상은 에이전트 수의 증가만으로 보장되지 않으며,
정보 전달 / 작업 분해 / 검증 구조를 어떻게 설계하느냐가 중요함.

Paper Fact — 논문에서 확인된 검증 사실

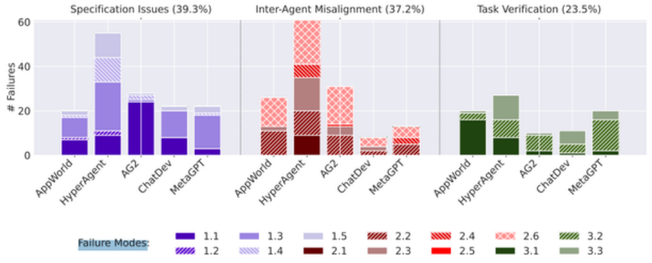
WHY DO MULTI-AGENT LLM SYSTEMS FAIL?

NeurIPS — MAST Framework

Multi-Agent LLM Systems는
어떤 상황에서, 왜 실패하는가?

- 5개 MAS 프레임워크
- 150개 이상의 태스크 트레이스추적, 분석

=> MAS의 실패를 개별 모델의 성능 문제만으로 보지 않고, 시스템 수준의 협력 실패 범주로 체계화하여 문제 파악의 틀 제시.



WHY DO MULTI-AGENT LLM SYSTEMS FAIL?

ACL — PMC Framework

복수의 제약 조건이 주어졌을 때
완수율을 높이는 기획 방식은 무엇인가?

With Unconventional Hint		GPT-3.5 + ReAct	GPT-4 + ReAct	GPT-3.5 + PMC	GPT-4 + PMC	GPT-4 (SP)
Validation Set (60)	Delivery Rate	98.33	98.33	91.67	96.67	100.00
	Common-sense Micro	74.38	79.38	63.54	87.29	92.08
	Common-sense Macro	0.00	8.33	1.67	43.33	50.00
	Hard Micro	0.71	7.14	0.71	47.14	52.86
	Constraint Macro	0.00	5.00	1.67	46.67	28.33
	Final Pass Rate	0.00	1.67	0.00	**33.33**	13.33
Test Set (308)	Delivery Rate	93.50	98.38	84.09	97.40	100.00
	Common-sense Micro	70.45	77.60	57.51	91.46	91.36
	Common-sense Macro	0.32	7.46	1.95	50.00	45.45
	Hard Micro	1.21	13.53	1.37	53.96	52.74
	Constraint Macro	0.32	9.74	1.30	45.12	29.22
	Final Pass Rate	0.00	2.92	0.65	**42.68**	14.94

- 복잡한 기획 과제

=> 계층적 하위 과제로 분해
=> 실행 가능한 동작으로 매핑함

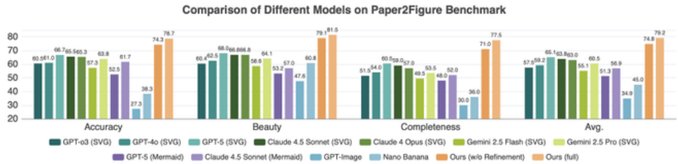
**multi-constraint planning의 성공률을 높임.
(Empirical Evidence: TravelPlanner 벤치마크 기준 PMC 42.68% vs GPT-4 2.92%)**

WHY DO MULTI-AGENT LLM SYSTEMS FAIL?

CVPR — Paper2Figure

복잡한 문맥을 시각화할 때 미학과 수정 가능성을
동시에 확보하는 방법은 무엇인가?

- End-to-End Diffusion의 레이아웃 제어 불능 및 단순 코드 생성 방식의 시각적 피드백 부재라는 한계를 파악함.



**FigScript를 도입하고, Generation Agent와 Refinement Agent의 역할을 분리함.
Iterative Refinement를 통해 정량적 성능 향상**

- **Accuracy +12%, Beauty +13.5%, Completeness +17.0%**

Paper2Figure: A Multi-Agent Collaborative System for Figure Generation

Synthesis — 세 논문의 시사점 종합

More Agents ≠ Automatically Better Results

정보 전달	자유로운 Agent 간 정보 교환 => **핸드오프를 구조화**
작업 분해	복잡한 제약을 한 번에 처리 => **계층적으로 분해**
검증·교정	생성 Agent의 자가 검증 => **독립적으로 검증하고 제한적으로 수정**

AI 카드뉴스 MAS 하이브리드 아키텍처

자유 텍스트 오염

기획 에이전트의 추상적 지시어가 디자인 계층으로 전달되며 발생하는 파싱 에러 및 의도 왜곡.

정형화된 규격 전달
: 핵심 핸드오프 정보는 자유 텍스트가 아닌 렌더링 파라미터가 명시된 JSON Schema

제약 조건 교착

"글자 수 제한" 전담 에이전트와 "필수 정보 포함" 전담 에이전트가 상호 출력을 거부(Reject)하며 시스템 정지.

계층적 과제 분해
: 복잡한 제작 지침을 분량, 톤앤매너, 레이아웃 등 전담 Subtask 단위 트리고 분해 후 실행.

맥락 파편화

하위 에이전트들이 국소적 제약 충족에만 매몰되어 카드뉴스 전체의 서사적 흐름 파괴.

독립 검증
: 생성 과정과 분리된 독립 Reviewer Agent가 최종 렌더링 결과물만을 기준으로 검증.

시각적 진동

폰트/여백 수정 시 다른 레이아웃 요소의 균형이 깨지는 트레이드오프 발생으로 무한 교정 루프 진입.

피드백 제한 및 충돌 해결
: Visual Feedback 루프 횟수를 최대 3회로 제한하고, 조건 충돌 시 메타 규칙 적용 후 미수렴 시 안전 기본 템플릿으로 Fallback.

More Agents, Better Results?
Not necessarily.
Better coordination, better results